

Relatório Comparativo: Desempenho de IA em Séries Temporais

Projeto: CardiolA - Monitoramento Contínuo IoT na Saúde (Fase 3)

Atividade: Ir Além 2 – Inteligência Artificial em séries temporais de saúde

Alunos: Tiago Alves Cordeiro, Matheus Parra, Otavio Custodio, Thiago Santos, Leandro Ferreira

Repositório: github.com/tiagoalvescordeiro/cardio-ia-fase1

Vídeo de Demonstração: youtu.be/mKrq-MxRo0s

1. Introdução e Objetivo

No contexto do monitoramento cardiológico em tempo real via Edge Computing (como no microcontrolador ESP32 adotado neste projeto), os sinais vitais como os batimentos por minuto (BPM) geram **séries temporais** ruidosas. O objetivo desta análise é aplicar técnicas de Inteligência Artificial para detectar anomalias nessas séries (como picos de taquicardia) e comparar duas metodologias:

- **Regressão Logística:** Um classificador estatístico tradicional.
- **Modelo LIF (Leaky Integrate-and-Fire):** Uma rede neuromórfica bio-inspirada que imita o comportamento de um neurônio pulsante.

2. Metodologia de Implementação

Para garantir um ambiente de teste isolado e comparável, geramos uma série temporal sintética no Python contendo 1.000 amostras. A linha base do BPM foi definida em 75, com ruído aleatório embutido para simular sensores reais. Foram injetados artificialmente "surto" de taquicardia (BPM > 115) para atuar como as anomalias alvo da detecção.

Ambos os modelos foram programados no ambiente Jupyter Notebook, sem o uso de processamento pesado em nuvem, focando em avaliar a viabilidade de execução diretamente na borda (Edge/IoT).

3. Avaliação de Desempenho e Arquitetura

3.1 O Classificador Tradicional: Regressão Logística

A Regressão Logística, por natureza, não lida com dados temporais sequenciais de forma contínua. Para contornar isso, empregamos a técnica de *Feature Engineering* conhecida como **Janela Deslizante (Sliding Window)**. Forçamos o modelo a "lembrar" do passado ao empacotar os 3 batimentos cardíacos anteriores como variáveis de entrada.

- **Acurácia:** Altíssima para detecção dos picos artificiais gerados no treino.
- **Problema de Ruído:** O modelo mostrou-se frágil contra *outliers* biológicos. Um único pico irreal (erro do sensor) pode forçar a classificação para uma anomalia grave.
- **Custo Computacional:** Exigir que o microcontrolador mantenha um *buffer* de janela e realize dezenas de multiplicações matriciais em ponto flutuante drena a bateria rapidamente.

3.2 O Modelo Neuromórfico: Leaky Integrate-and-Fire (LIF)

A rede LIF abandona as matrizes estatísticas em favor de uma equação dinâmica que simula o estresse do músculo cardíaco. Definimos o "Estímulo" como a diferença entre o BPM atual e a zona de repouso. Cada batimento alto adiciona carga a uma variável interna chamada **Potencial de Membrana**. Se esse potencial cruzar a barreira limite (*Threshold* de 5.0), o neurônio "dispara" o alerta de emergência e esvazia a carga. Para evitar falsos alertas, o neurônio possui uma taxa de "Vazamento" (*Leak* = 0.8) que limpa a carga ociosa.

- **Resiliência Orgânica:** O LIF ignorou completamente picos isolados. O alerta só disparou quando o acúmulo da taquicardia se manteve por vários segundos.
- **Zero Memória Explícita:** Não há janelas deslizantes. O LIF precisou armazenar apenas uma variável (o potencial) na memória RAM, poupando processamento máximo do dispositivo IoT.

4. Comparativo de Vantagens e Limitações

Critério de Análise	Regressão Logística (Janelas)	Neuromórfico (LIF Neuron)
Processamento Requerido	Moderado (Operações matriciais/sigmoides contínuas)	Mínimo (Apenas uma soma e multiplicação)
Uso de Memória RAM	Alto (Necessita armazenar histórico passado)	Irrisório (Guarda apenas o estado atual de tensão)
Reação a Falsos Positivos	Alta sensibilidade a <i>outliers</i> repentinos.	Robusta. Vazamento (Leak) filtra ruídos isolados.
Fase de Treinamento	Obrigatória e computacionalmente cara.	Adaptativa. Ajuste manual de limiares clínicos.

5. Conclusão e Escolha Estratégica

Enquanto a Regressão Logística é uma ferramenta formidável para a construção de *Dashboards* e processamento posterior na nuvem (Cloud Computing), ela peca no monitoramento imediato do hardware vestível (IoT Wearable).

A implementação do **modelo LIF provou ser a arquitetura ideal** para as ambições do projeto CardiolA. Ele permite que o processamento preditivo ocorra localmente no ESP32 (Edge Computing), sem dependência de internet constante, utilizando quase nenhuma bateria e protegendo a equipe médica de alarmes falsos causados por erros de biotelemetria momentânea. Este modelo é o alicerce biológico perfeito para a saúde digital do futuro.